

WWII Letters Analysis

NLP-проект для анализа тональности и эмоций в письмах периода ВОВ (1941–1945)

Этот проект представляет собой автоматизированный пайплайн для сбора, обработки и анализа текстов фронтовых писем. С помощью нейросетевой модели (RuBERT) и лингвистического анализа определяются динамика настроения, средняя длина текстов и доминирующие эмоции солдат на протяжении всех лет войны.

Структура проекта

```
WWII_Letters_Analysis/  
├── data/                                # Данные (исходные и обработанные)  
│   ├── letters_database.json # База собранных писем (RAW)  
│   └── letters_enriched.json # Обработанные данные с тегами (NLP)  
├── scripts/                             # Утилиты для работы с данными  
│   ├── collect_letters.py  # Интерактивный сбор писем  
│   └── process_letters.py  # NLP-обработка (тональность, эмоции)  
├── src/                                # Основной код приложения  
│   ├── analysis/           # Статистический анализ  
│   │   ├── temporal_analysis.py  
│   │   └── hypothesis_test.py  
│   ├── nlp/                # Модели и словари  
│   │   ├── sentiment_analyzer.py  
│   │   └── emotion_dictionary.py  
│   ├── visualization/     # Графики и отчёты  
│   │   └── plots.py  
│   ├── config.py          # Конфигурация путей  
│   └── main.py             # Точка входа (запуск пайплайна)  
├── results/               # Результаты работы (графики, json)  
├── requirements.txt        # Зависимости  
└── README.md              # Документация
```

Как запустить

1) Установка зависимостей

Убедитесь, что у вас установлен Python 3.8+. Создайте виртуальное окружение и установите библиотеки. Для этого запустите в терминале в корневой папке проекта команды:

```
python -m venv .venv
.venv\Scripts\activate # Для Windows
pip install -r requirements.txt
```

2) Сбор данных (Опционально)

Скрипт помогает вручную добавлять письма в базу. Запускается интерактивно, позволяет вставлять тексты с сохранением абзацев:

```
python scripts/collect_letters.py
```

3) Обработка данных (NLP)

Этот шаг прогоняет тексты через модель RuBERT, определяет тональность (позитив/негатив/нейтрал) и эмоции по ключевым словам (страх, надежда, тоска и т.д.). Результат сохраняется в `data/letters_enriched.json`.

```
python scripts/process_letters.py
```

4) Анализ и визуализация

Запускает полный пайплайн: проверка статистических гипотез, построение графиков динамики и генерация итогового отчёта.

```
python src/main.py
```

Результаты (графики и JSON-отчёт) сохраняются в папку `results/`.

Используемые технологии

- **NLP:** `transformers`, `torch` (модель: `cointegrated/rubert-tiny-sentiment-balanced`)
- **Анализ данных:** `pandas`, `numpy`, `scipy`
- **Визуализация:** `matplotlib`, `seaborn`
- **Инструменты:** `json`, `pathlib`

Описание исследования

Проект проверяет две исторические гипотезы на основе данных:

1. **Длина писем:** Становятся ли письма короче к концу войны?
2. **Тональность:** Уменьшается ли доля негативных эмоций к победе?

Используется комбинированный подход: классификация тональности нейросетью + словарный метод для выделения специфических эмоций.

Учебный проект.

Выполнил: Золин Егор Станиславович

Год: 2026